Python w zastosowaniach inżynierskich

Podstawy analizy i wizualizacji danych

Tydzień 2 – Samochody na skrzyżowaniu

Przez pewien czas prowadzono obserwację ruchu samochodowego na skrzyżowaniu. W kolejnych, jednominutowych przedziałach czasu rejestrowano liczbę samochodów, które przejechały przez skrzyżowanie. Dane z obserwacji znajdują się w pliku `cars.csv`. Każdy wiersz pliku odpowiada jednemu przedziałowi jednominutowemu.

1. Wczytaj dane i przedstaw je w postaci histogramu. Zbadaj, jakie wartości liczby samochodów występują najczęściej oraz jak szeroki jest rozrzut obserwowanych wartości.

2. Oblicz średnią, wariancję oraz odchylenie standardowe liczby samochodów przypadających na jedną minutę. Porównaj otrzymane wartości i sprawdź, czy średnia i wariancja są do siebie zbliżone.

3. Załóżmy, że liczba samochodów przejeżdżających przez skrzyżowanie w ciągu jednej minuty może być opisana rozkładem Poissona
$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$
Przyjmij, że parametr λ jest równy średniej liczbie samochodów przypadających na jedną minutę i użyj wartości wyznaczonej na podstawie danych. Następnie oblicz prawdopodobieństwa $P(X = k)$ dla kolejnych wartości k występujących w danych.

4. Porównaj rozkład Poissona z rozkładem empirycznym uzyskanym z obserwacji. Dla każdej wartości k oblicz oczekiwaną liczbę obserwacji
$$n_k^{\text{model}} = NP(X = k),$$
gdzie N jest całkowitą liczbą obserwacji. Przedstaw na jednym wykresie liczności obserwowane oraz oczekiwane według modelu. Oceń jakościowo, na ile rozkład Poissona opisuje obserwowane dane.

5. Korzystając z otrzymanego modelu, oblicz prawdopodobieństwo, że w ciągu jednej minuty przez skrzyżowanie przejedzie co najmniej 15 samochodów.

6. Sprawdź, czy intensywność ruchu samochodowego zmieniała się w czasie. Podziel obserwacje na kolejne godzinne przedziały i dla każdej godziny oblicz średnią liczbę samochodów przypadających na jedną minutę. Oblicz względną zmianę średniej godzinowej względem średniej dla całego zbioru i przedstaw ją na wykresie. Oceń, czy przyjęcie jednej wartości parametru λ dla całego zbioru danych jest uzasadnione.