Python w zastosowaniach inżynierskich

Podstawy analizy i wizualizacji danych

Tydzień 3 – Rozpoznawanie cyfr metodami uczenia maszynowego

W ramach zadania wykorzystamy zbiór danych zawierający obrazy odręcznie zapisanych cyfr od 0 do 9. Każdy obraz ma rozmiar 8×8 pikseli, a jego poszczególne piksele opisane są wartościami liczbowymi. Zbiór danych jest dostępny w bibliotece `scikit-learn`.

1. Wczytaj zbiór danych za pomocą funkcji `load_digits` z biblioteki `scikit-learn`. Sprawdź rozmiar zbioru danych oraz przedstaw kilka przykładowych obrazów wraz z odpowiadającymi im etykietami. Wyświetl również przykładowy obraz w postaci macierzy wartości pikseli.

2. Podziel dane na zbiór treningowy i testowy. Zbiór treningowy powinien zawierać 80% wszystkich przykładów, a pozostałe 20% przeznacz na testowanie algorytmu. Zbiór testowy pozostaw niezmieniony podczas dalszej analizy.

3. Zaimplementuj algorytm klasyfikacji najbliższych sąsiadów (KNN, *k-nearest neighbors*). Dla badanego obrazu oblicz jego odległość euklidesową od wszystkich obrazów ze zbioru treningowego, znajdź k najbliższych przykładów i przypisz badanemu obrazowi etykietę, która występuje najczęściej wśród jego sąsiadów. Odległość euklidesowa pomiędzy dwoma wektorami $\mathbf{x}$ i $\mathbf{y}$ jest dana wzorem
$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}.$$

4. Zastosuj zaimplementowany algorytm do wszystkich obrazów ze zbioru testowego. Oblicz skuteczność klasyfikacji
$$\text{accuracy} = \frac{\text{liczba poprawnie rozpoznanych obrazów}}{\text{liczba wszystkich obrazów testowych}}.$$
Przyjmij początkowo $k = 3$ i oceń, jak skutecznie algorytm rozpoznaje cyfry.

5. Sprawdź, jak skuteczność klasyfikacji zależy od liczby dostępnych przykładów treningowych. Przeprowadź klasyfikację dla kilku różnych rozmiarów zbioru treningowego, pozostawiając ten sam zbiór testowy. Przedstaw na wykresie zależność skuteczności klasyfikacji od liczby przykładów treningowych dla kilku różnych wartości k, w tym zarówno małych, jak i większych. Następnie krótko zinterpretuj otrzymane wyniki.