Python w zastosowaniach inżynierskich

Podstawy analizy i wizualizacji danych

Tydzień 3 – Rozpoznawanie cyfr metodami uczenia maszynowego

W ramach zadania wykorzystamy zbiór danych zawierający obrazy odręcznie zapisanych cyfr od 0 do 9. Każdy obraz ma rozmiar 8×8 pikseli, a jego poszczególne piksele opisane są wartościami liczbowymi. Zbiór danych jest dostępny w bibliotece `scikit-learn`.

1. Wczytaj zbiór danych za pomocą funkcji `load_digits` z biblioteki `scikit-learn`. Sprawdź rozmiar zbioru danych oraz przedstaw kilka przykładowych obrazów wraz z odpowiadającymi im etykietami. Wyświetl również przykładowy obraz w postaci macierzy wartości pikseli.

2. Podziel dane na zbiór treningowy i testowy. Zbiór treningowy powinien zawierać 80% wszystkich przykładów, a pozostałe 20% przeznacz na testowanie algorytmu. Zbiór testowy pozostaw niezmieniony podczas dalszej analizy.

3. Zaimplementuj algorytm klasyfikacji najbliższych sąsiadów (KNN, *k-nearest neighbors*). Dla badanego obrazu oblicz jego odległość euklidesową od wszystkich obrazów ze zbioru treningowego, znajdź k najbliższych przykładów i przypisz badanemu obrazowi etykietę, która występuje najczęściej wśród jego sąsiadów. Odległość euklidesowa pomiędzy dwoma wektorami $\mathbf{x}$ i $\mathbf{y}$ jest dana wzorem
$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}.$$

4. Zastosuj zaimplementowany algorytm do wszystkich obrazów ze zbioru testowego. Oblicz skuteczność klasyfikacji
$$\text{accuracy} = \frac{\text{liczba poprawnie rozpoznanych obrazów}}{\text{liczba wszystkich obrazów testowych}}.$$
Przyjmij początkowo $k = 3$ i oceń, jak skutecznie algorytm rozpoznaje cyfry.

5. Sprawdź, jak skuteczność klasyfikacji zależy od liczby dostępnych przykładów treningowych. Przeprowadź klasyfikację dla kilku różnych rozmiarów zbioru treningowego, pozostawiając ten sam zbiór testowy. Przedstaw na wykresie zależność skuteczności klasyfikacji od liczby przykładów treningowych dla kilku różnych wartości k, w tym zarówno małych, jak i większych. Następnie krótko zinterpretuj otrzymane wyniki.

Tydzień 4 – Rozpoznawanie cyfr metodami uczenia maszynowego

1. Zaimplementuj metodę najbliższego centroidu (*nearest centroid*). Dla każdej cyfry oblicz średni obraz spośród wszystkich przykładów tej cyfry w zbiorze treningowym. Jeśli $\mathbf{x}_1, \ldots, \mathbf{x}_N$ oznaczają obrazy należące do danej cyfry, jej centroid $\mathbf{c}$ jest dany wzorem

$$\mathbf{c} = \frac{1}{N} \sum_{j=1}^{N} \mathbf{x}_j.$$

   Przedstaw obliczone centroidy w postaci obrazów opisanych odpowiednimi etykietami.

2. Zastosuj metodę najbliższego centroidu do klasyfikacji obrazów ze zbioru testowego. Dla każdego obrazu oblicz jego odległość od dziesięciu centroidów i przypisz mu etykietę odpowiadającą najbliższemu centroidowi. Oblicz skuteczność klasyfikacji.

3. Porównaj działanie obu zaimplementowanych algorytmów. Przedstaw na jednym wykresie zależność skuteczności klasyfikacji od liczby przykładów treningowych metodą KNN oraz metodą najbliższego centroidu. W przypadku algorytmu KNN uwzględnij kilka wartości parametru k rozważanych w punkcie 5. z poprzedniego tygodnia.

4. Zaimplementuj funkcję obliczającą macierz pomyłek (*confusion matrix*) na podstawie rzeczywistych etykiet oraz etykiet przewidzianych przez klasyfikator. Macierz powinna mieć rozmiar 10×10, a jej element C_{ij} powinien oznaczać liczbę obrazów przedstawiających cyfrę i, które zostały sklasyfikowane jako cyfra j.

   Oblicz i przedstaw graficznie macierze pomyłek dla obu zaimplementowanych algorytmów. Wskaż, które cyfry są najczęściej rozpoznawane poprawnie, a które są najczęściej mylone z innymi. Zwróć uwagę na elementy leżące poza główną przekątną macierzy.